

Selekcija algoritma pretrage stabla igre

Istraživanje podataka 2: Seminarski rad

Primena klasifikacije na problem selekcije algoritma (Rice, 1976)

Anđela Spasić

Matematički fakultet, Univerzitet u Beogradu
2025/2026

Sadržaj

1 Tekst zadatka

Zadatak je primeniti metode istraživanja podataka na sopstveni sintetički skup stabala igre, sa ciljem da se predvidi koji od dva algoritma pretrage, Alpha-Beta (AB) ili Monte Carlo Tree Search (MCTS), daje bolji rezultat na datom stablu, pod ograničenim budžetom pretrage (brojem čvorova koje algoritam sme da poseti).

Problem se formalizuje kao instanca *problema selekcije algoritma* (Rice, 1976). Kao mera selekcije, u ovom radu koriste se dva glavna cilja klasifikacije nad istim skupom:

- **which_algo**: da li je algoritam a pronašao globalno optimalan prvi potez na stablu x , prema iscrpnom minimax rešavaču;
- **which_better**: čiji je od dva izabrana poteza (AB-ovog ili MCTS-ovog) vrednosno bolji, nezavisno od toga da li je bilo koji od njih zaista optimalan.

Cilj je naučiti model da predviđa koji algoritam će dati bolji rezultat, pre nego što se ijedan od njih pokrene.

Optimalni potez i tačne vrednosti poteza definišu se iscrpnim minimax pretraživanjem koje poseti svaki čvor stabla. Ovakvo pretraživanje je izvodljivo samo na sintetičkim stablima kontrolisane veličine, pa se stabla generišu programski, upravo da bi iscrpni minimax mogao da posluži za obeležavanje, tako da AB i MCTS imaju sa čime da se porede.

Seminarski rad obuhvata:

- generisani sintetički skup podataka (16 978 stabala, 91 atribut, od čega 81 prediktorski i 10 ciljnih/izvedenih)
- pretprocesiranje podataka
- klasifikaciju sa sedam algoritama i poređenje na tri skupa atributa (svi, strukturni, redukovani)
- vizualizaciju podataka u 2D prostoru (PCA, t-SNE)
- modele za više ciljnih promenljivih (**which_better**, **which_algo**, **ab_correct**, **mcts_correct**, **margin_category**, **tree_difficulty**)
- tekstualni opis i tumačenje rezultata

2 Opis skupa podataka

2.1 Generisanje stabala

Svako stablo se gradi rekursivno počev od korena. Vrednost svakog čvora živi u neograničenom prostoru i predstavlja slučajni hod: dete nasleđuje vrednost roditelja uz mali Gausov pomak,

$$\ell_{\text{dete}} = \ell_{\text{roditelj}} + \mathcal{N}(0, \sigma^2), \quad \sigma = \frac{\text{spread}}{\sqrt{\text{max_depth}}},$$

gde *spread* kontroliše koliko brzo se vrednosti grana razilaze od korena ka listovima. Nakon toga se vrednost projektuje u interval $[-1, 1]$ preko tanh: list dobija pravu vrednost $v = \tanh(\ell)$, a svaki unutrašnji čvor dobija *heurističku* vrednost $\tanh(\ell + \mathcal{N}(0, (\text{heur_noise} \cdot r)^2))$, gde je r udeo preostale dubine do lista. Heuristika je namerno nepouzdanija bliže korenu, gde AB najčešće mora da je koristi jer budžet ne dopire do pravih listova.

Tipovi čvorova. Koren uvek ima bar dva deteta (da postoji stvaran izbor poteza). Svaki unutrašnji čvor je jedan od:

- MAX: vrednost = max dece (naizmenično sa MIN po parnosti dubine)
- MIN: vrednost = min dece
- CHANCE: slučajni događaj, vrednost = mean dece; javlja se na bilo kojoj dubini > 0 sa verovatnoćom *chance_density*, koja je za 15% stabala tačno 0.0 (potpuno deterministička stabla), a inače uniformno izvučena iz $[0, 0.9]$
- LEAF: terminalni čvor

Broj dece po čvoru je Gausov uzorak oko faktora grananja koji je jedan od parametara generisanja, a dodatno određeni broj čvorova (van korena) postaje list pre dostizanja maksimalne dubine, čime stabla postaju nepravilna umesto savršeno balansirana. Maksimalna dubina se bira tako da *očekivani* broj čvorova ne pređe 30 000, sa apsolutnim maksimumom od 10 nivoa. Kako se stvarni broj dece po čvoru izvlači iz Gausove raspodele, a ne fiksira na tu procenu, realizovano stablo može znatno odstupiti u oba pravca, otuda u konačnom skupu ima stabala i sa svega stotinak i sa preko 50 000 čvorova.

Algoritmi.

- **Minimax** (tačni rešavač): iscrpna rekurzija bez ograničenja budžeta ili dubine. Uvek tačan po definiciji; služi isključivo za obeležavanje.
- **Alpha-Beta** (AB): iterativno produbljivanje, pretražuje na dubini 1, pa 2, itd., dok budžet čvorova ne bude na izmaku; zadržava se vrednosti poteza sa poslednje potpuno završene dubine. AB nigde ne čita tip čvora, nego alternira max/min isključivo po parnosti dubine poziva, pa CHANCE čvorove tretira kao obične MAX/MIN čvorove.
- **MCTS** (UCT): budžet se meri brojem *dodirnutih* čvorova tokom selekcije, ekspanzije i rollout-a do pravog lista, odnosno rollout se takođe naplaćuje iz budžeta. Pri selekciji, CHANCE čvorovi se uzorkuju ravnomerno slučajno, dok se MAX/MIN čvorovi biraju UCB1 formulom $Q(k) + c\sqrt{\ln N(\text{roditelj})/N(k)}$, $c = \sqrt{2}$, sa Q negiranim na MIN čvorovima. Finalni potez je dete korena sa najviše poseta.

Pošto je MCTS nasumičan, svako stablo se rešava sa 5 nezavisnih, seedovanih ponavljanja MCTS-a, pa je `mcts_correct` definisan kao većinski glas (bar 3 od 5 tačna), a `mcts_correct_rate` kao kontinualan udeo tačnih ponavljanja.

Isti čvorni budžet, izveden kao udeo ukupnog broja čvorova stabla (log-uniformno iz $[0.02, 0.7]$, sa minimumom od 20), koristi se za AB i za svako MCTS ponavljanje, čime je poredenje pravedno: oba algoritma rade pod istim ograničenjem resursa.

Generisano je 20 000 stabala; zadržano je 16 978 (ostatak je odbačen jer je imao manje od 80 čvorova ili manje od dva deteta korena, dakle degenerisani slučajevi bez stvarnog izbora).

2.2 Atributi

Skup ima 91 kolonu: 81 prediktorski atribut i 10 ciljnih/izvedenih promenljivih (`which_algo`, `which_better`, `margin_category`, `ab_correct`, `mcts_correct`, `mcts_correct_rate`, `is_contested`, `delta`, `ab_regret`, `mcts_regret`). Prediktorski atributi se dele u sedam grupa, prema tome da li se mogu izračunati iz same strukture stabla ili zahtevaju da neki algoritam (AB, MCTS ili orakl) zaista bude pokrenut:

- **Parametri generisanja (4):** `branching_factor`, `depth`, `chance_node_density`, `heur_noise_param`;

- **Globalna struktura (24):** brojevi čvorova različitih tipova (`total_nodes/leaves/internal_nodes`) izvedeni odnosi (`leaf_to_internal_ratio`, `chance_node_fraction`, `leaf_density`), prosek i standardno odstupanje broja dece po čvoru (`branching_mean/std`), ostvarena dubina lista (`realized_max_depth`, `leaf_depth_mean/std`) i deset opisnih statistika vrednosti listova (`leaf_value_mean/std/min/max/range/median`, `leaf_iqr`),
- **Struktura po dubini (25):** `node_count_dk`, `chance_node_count_dk`, `leaf_value_mean_dk`, `leaf_value_std_dk`, `branching_mean_dk` za $k = 1, \dots, 5$;
- **Budžet i grananje iz korena (12):** `node_budget`, `budget_coverage`, `ab_reach_depth` ($= \log(budget)/\log(bf)$, koliko nivoa dubine AB realno dostiže), `depth_deficit`, `depth_deficit_rel`, `branch_top2_gap`, `branch_mean_spread`, `branch_value_skew`, `top2_size_ratio`, `top2_depth_diff`, `chance_frac_top1/top2`
- **Kvalitet heuristike (3):** `heur_incoherence` (i njegovo standardno odstupanje `heur_incoherence_std`) meri koliko se heuristička vrednost čvora razlikuje od one koju bi dala prava minimax/mean propagacija dece, `heur_noise_to_signal` poredi zadati šum heuristike sa stvarnim rasipanjem vrednosti listova. Iako opisuju kvalitet evaluacione funkcije, sva tri atributa se računaju direktno iz heurističkih i pravih vrednosti dodeljenih pri generisanju stabla, pa su dostupni i pre pokretanja bilo kog algoritma pretrage
- **Atributi ponašanja AB-a i MCTS-a (9):** merenja koja postoje samo zato što je algoritam zaista pokrenut: kod AB-a `ab_nodes_visited`, `ab_pruning_rate`, `ab_root_eval_std`, `ab_instability`, `ab_depth_reached`, `ab_ranking_correlation`, kod MCTS-a `mcts_vote_margin`, `mcts_visit_entropy`, `mcts_best_value_estimate`
- **Atributi tačnog rešavača (4):** tačne vrednosti iz iscrpnog minimaxa (`exact_best_value`, `exact_second_best_value`, `best_move_margin`, `best_move_margin_normalized`), dostupne tek nakon što se Minimax pokrene

Skup atributa po dubini pokriva prvih pet nivoa ($k = 1, \dots, 5$), umesto svih nivoa do maksimalne dubine stabla (koja ide i do 10): dublji nivoi bi na manjim stablima gotovo uvek bili prazni ili nula, pa ne bi nosili stvaran signal, samo bi indirektno kodirali faktor grananja preko toga koliko kolona uopšte ima nenultu vrednost, što bi kvarilo generalizaciju

2.3 Ciljne promenljive

- `which_better` (nominalna, 3 klase): čiji je izabrani potez bolji, AB / MCTS / Tie; glavni cilj;
- `which_algo` (nominalna, 4 klase): koji algoritam pronalazi optimalni potez, AB / MCTS / Both / Neither; sporedni cilj;
- `ab_correct`, `mcts_correct` (binarne): da li je svaki algoritam pojedinačno tačan;
- `mcts_correct_rate` (kontinualna): udeo od 5 MCTS ponavljanja koja su pogodila optimum;
- `margin_category` (ordinalna, 3 klase): za koliko pobednik vodi, low / medium / high;
- `is_contested` (binarna): identično `margin_category = low` (prag 0.1).


`which_algo` i `which_better` odgovaraju na različita pitanja: algoritam koji promaši baš optimalan potez, ali izabere drugi najbolji, gubi po `which_algo` a može pobediti po `which_better`. U pretprocesiranju se iz `which_algo` izvodi i `tree_difficulty` (Both->easy, AB/MCTS->medium, Neither->hard).

2.4 Raspodela klasa


Tabela 1: Raspodela klasa `which_algo` i `which_better`

which_algo			which_better		
Klasa	Broj	Udeo	Klasa	Broj	Udeo
Both	6203	36.5%	AB	6330	37.3%
Neither	5445	32.1%	Tie	5684	33.5%
MCTS	2756	16.2%	MCTS	4964	29.2%
AB	2574	15.2%			
Ukupno	16 978	100%	Ukupno	16 978	100%

`which_algo` je neravnomerno: klasa `Both` je više od dva puta zastupljenija od `AB` (tabela iznad), jer oba algoritma budu tačna kad god je budžet makar umeren ili je stablo strukturno lako. Kod `which_better` ta neravnoteža je znatno blaža: sve tri klase su reda veličine 30–37%, iako `AB` ima blagu prednost nad `MCTS`-om. Razlog je verovatno to što `MCTS`-ov budžet uključuje i cenu rolauta, pa `MCTS` pod istim brojem dodirnutih čvorova stigne da odigra nešto manje selekcije/ekspanzije nego `AB`. Uprkos tome, `which_better` ostaje uravnoteženiji cilj od `which_algo`, što je jedan od razloga zašto je odabran za glavni cilj klasifikacije.




Slika 1: Raspodela klasa `which_algo`



Slika 2: Raspodela klasa `which_better`

MCTS-ova nestabilnost je izmerena direktno: na 64.6% stabala se svih 5 ponavljanja slaže (uvek tačno ili uvek pogrešno), dok na 35.4% stabala ponavljanja daju različit ishod.



Slika 3: Udeo od 5 MCTS ponavljanja koja su pogodila optimum, po stablu

2.5 Opisna statistika


Skup ima 16978 slogova i 91 atribut: 62 tipa `float64`, 26 tipa `int64` i 3 tekstualna (`which_algo`, `margin_category`, `which_better`). Nema nedostajućih vrednosti.

Tabela 2: Opseg i srednja vrednost parametara generisanja i budžeta

Atribut	Min	Srednja	Maks
<code>branching_factor</code>	2	8.39	14
<code>depth</code>	2	3.97	10
<code>chance_node_density</code>	0.0	0.38	0.9
<code>heur_noise_param</code>	0.0	0.75	1.5
<code>budget_coverage</code>	2.0%	20.5%	69.9%

Gustina CHANCE čvorova ima primetnu masu tačno na nuli, namerna posledica, kako bi imali dodatnih 15% potpuno determinističkih stabala koja pogoduju AB-u.


Veličina stabla je izrazito desno zakošena: prosečno 5599 čvorova, ali medijana svega 1472, jer broj čvorova raste eksponencijalno sa faktorom grananja, pa nekoliko velikih stabala (do 51 771 čvorova) povlači srednju vrednost znatno iznad tipičnog slučaja. `ab_reach_depth` (koliko nivoa dubine budžet realno dostiže) prati istu logiku u suprotnom smeru: prosečno dostiže tek 2.88 nivoa.



Slika 4: Raspodela parametara generisanja i budžeta

3 Eksplorativna analiza podataka

3.1 Atributi po klasama




Slika 5: Raspodela šest ključnih atributa po klasi which_algo


Faktor grananja je najizrazitiji strukturni separator: stabla iz klase Neither imaju u proseku najveći faktor grananja (9.28), Both najmanji (7.42), dok AB i MCTS leže između

njih dvoje i liče jedna na drugu (slika iznad). Gustina CHANCE čvorova pre svega izdvaja MCTS, koja je u proseku gušća nego kod preostale tri klase.

3.2 Korelaciona analiza



Slika 6: Pearsonova korelacija numeričkih atributa sa ab_correct i mcts_correct



Slika 7: Korelaciona matrica odabranih atributa

Tabela 3: Najjače Pearsonove korelacije sa `ab_correct` i `mcts_correct`



Atribut	<code>ab_correct</code>	<code>mcts_correct</code>
<code>ab_ranking_correlation</code>	0.398	–
<code>mcts_vote_margin</code>	0.286	0.441
<code>branch_top2_gap</code>	0.257	–
<code>ab_reach_depth</code>	0.179	0.357
<code>depth</code>	0.175	0.316
<code>best_move_margin</code>	0.240	–
<code>branching_factor</code>	–0.175	–0.198
<code>mcts_visit_entropy</code>	–0.265	–0.382

Za oba cilja, najjača korelacija dolazi od atributa ponašanja algoritama (`ab_ranking_correlation`, `mcts_vote_margin`), što je očekivano jer oba direktno mere sigurnost algoritma u trenutku odluke, ne samo opštu težinu stabla. Od strukturnih atributa, dostupnih pre pokretanja, budžet i margina korena (`branch_top2_gap`, `best_move_margin`) pokazuju najjaču pozitivnu vezu, a veći faktor grananja ide uz nižu tačnost oba algoritma.

Zanimljivo je da `ab_reach_depth` i `depth` jako koreliraju i sa `mcts_correct`, iako direktno mere AB-ov budžet, ne MCTS-ov. Razlog je da veći `depth` u ovom skupu ide uz manji faktor grananja (stabla su ograničena na $\approx 30\,000$ čvorova), pa oba algoritma profitiraju od istog, lakšeg tipa stabla. `mcts_visit_entropy` je negativno korelisan sa oba cilja: visoka entropija poseta (MCTS ravnomerno raspoređuje posete po svoj deci umesto da se skoncentriše na jedno) je opštiji signal da je stablo teško, ne samo da je MCTS neodlučan.

3.3 Vizualizacija u 2D prostoru

PCA. Primenjena na 68 strukturnih atributa (izuzimajući ciljne kolone i kolone koje opisuju ponašanje algoritama). Prve dve komponente objašnjavaju zajedno 34.7% varijanse (PC1: 21.9%, PC2: 12.8%), a potrebno je 13 komponenti za 80% varijanse.




(a) PCA rasejani dijagram, obojen po `which_algo`

(b) Kumulativna objašnjena varijansa

Slika 8: PCA vizualizacija

Klase nisu linearno razdvojive u 2D projekciji: gotovo 65% informacije se gubi pri svođenju na dve komponente, pa je za pouzdanu klasifikaciju potreban nelinearan model (odjeljak 5).

t-SNE. Nelinearna vizualizacija na prvih 26 PCA komponenti, uzorak od 4000 stabala.



Slika 9: t-SNE vizualizacija, obojena po `which_algo`

t-SNE otkriva lokalne nakupine pretežno jedne klase, ali sa značajnim preklapanjem. Problem je, dakle, naučiv iz strukturnih atributa, ali nije trivijalan.

4 Pretprocesiranje podataka

4.1 Izvedeni atributi

- `ab_coverage` = `ab_nodes_visited`/`total_nodes`: koliko je AB stvarno obišao, za razliku od `budget_coverage` koji je *nameravani* budžet. Srednja vrednost 0.201, korelacija sa `budget_coverage` 0.993 (skoro identične, jer AB retko iscrpi budžet pre nego što dostigne kraj iteracije);
- `mcts_unanimous`: da li se svih 5 MCTS ponavljanja slaže (64.6%, videti odeljak 2.4);
- `depth_chance_inter` = `depth` × `chance_node_density`: jeftina interakcija dve ose generatora;
- `is_tie`: `which_better` = Tie (5684 od 16 978, 33.5%);
- `tree_difficulty`: easy/medium/hard izvedeno iz `which_algo` (6203 / 5330 / 5445).

Ove poslednje dve, `ab_coverage` i `mcts_unanimous`, spadaju u attribute ponašanja algoritama (odjeljak 5.1 ih izbacuje iz skupa B), jer zahtevaju da AB, odnosno MCTS, zaista budu pokrenuti.

4.2 Čišćenje podataka

Skup nema nedostajućih vrednosti. Autlajeri su provereni IQR i 3σ metodom na šest ključnih atributa:

Tabela 4: Analiza autlajera

Atribut	IQR autlajeri	%	3σ autlajeri	%
total_nodes	1748	10.3%	364	2.1%
best_move_margin	855	5.0%	328	1.9%
mcts_vote_margin	1533	9.0%	346	2.0%
heur_incoherence	403	2.4%	197	1.2%
leaf_value_std	66	0.4%	68	0.4%
ab_pruning_rate	2	0.0%	11	0.1%

Autlajeri se zadržavaju: nisu greške merenja, već realne ali ređe konfiguracije stabla (npr. veoma veliko stablo je validan, ne pogrešan, parametar). Njihovo brisanje bi uklonilo informaciju relevantnu za klasifikaciju.

4.3 Kodiranje kategoričkih atributa

`margin_category` i `tree_difficulty` su ordinalne i kodiraju se `OrdinalEncoder`-om sa eksplcitnim redosledom (`low<medium<high`, `easy<medium<hard`). `which_algo` i `which_better` su nominalne i kodiraju se `LabelEncoder`-om: `which_algo` – $\rightarrow \{AB=0, Both=1, MCTS=2, Neither=3\}$, `which_better` – $\rightarrow \{AB=0, MCTS=1, Tie=2\}$.

4.4 Standardizacija

84 numerička prediktorska atributa (sve osim ciljnih/izvedenih kolona) se standardizuju `StandardScaler`-om, $z = (x - \mu)/\sigma$, obavezno pre logističke regresije i neuronske mreže. Naučeni scaler se čuva u `models/scaler.pkl` radi identične transformacije na budućim podacima bez ponovnog fitovanja.


4.5 Izbor podskupa atributa

Cilj izbora je `which_better`. Tri grupe metoda glasaju nezavisno:

Filter. Korelaciona eliminacija ($|r| \geq 0.99$): $84 - \rightarrow 74$ atributa (`total_leaves` $\leftrightarrow$ `total_nodes` $r=0.995$; `leaf_to_internal_ratio` $\leftrightarrow$ `branching_factor` $r=0.994$; `branching_mean` $\leftrightarrow$ `branching_factor` $r=0.994$; `realized_max_depth` $\leftrightarrow$ `depth` $r=1.000$; `leaf_depth_mean` $\leftrightarrow$ `depth` $r=1.000$; `leaf_fraction_positive` $\leftrightarrow$ `leaf_value_mean` $r=0.991$; `branching_mean_d1` $\leftrightarrow$ `leaf_to_internal_ratio` $r=0.993$; `ab_nodes_visited` $\leftrightarrow$ `node_budget` $r=1.000$; `best_move_margin` $\leftrightarrow$ `best_move_margin` $r=0.998$; `ab_coverage` $\leftrightarrow$ `budget_coverage` $r=0.993$). Kvazi-konstantni prag (jedna vrednost $> 99\%$ redova) ne eliminiše ništa ($74 - \rightarrow 74$). ANOVA F-test (`SelectKBest`) bira top 37 od 74.

Wrapper. Rekurzivna eliminacija (RFE, logistička regresija) do $74 - \rightarrow 37$ atributa.

Embedded. Slučajne šume (100 stabala), top 37 po Ginijevoj važnosti.



Slika 10: Top 20 atributa po važnosti u Slučajnim šumama (izbor atributa)

Ansambl glasanje. Atribut ulazi u finalni skup ako ga izabere bar 2 od 3 grupe:

Tabela 5: Finalni skup atributa (33 atributa, $\geq 2/3$ glasova)

Atribut	ANOVA	RFE	RF	Glasovi
ab_depth_reached	X	X	X	3
ab_instability	X	X	X	3
ab_pruning_rate	X	X	X	3
ab_ranking_correlation	X	X	X	3
ab_reach_depth	X	X	X	3
best_move_margin	X	X	X	3
branch_top2_gap	X	X	X	3
budget_coverage	X	X	X	3
depth_deficit_rel	X	X	X	3
leaf_depth_std	X	X	X	3
mcts_best_value_estimate	X	X	X	3
mcts_unanimous	X	X	X	3
mcts_visit_entropy	X	X	X	3
mcts_vote_margin	X	X	X	3
node_budget	X	X	X	3
total_internal_nodes	X	X	X	3
total_nodes	X	X	X	3
ab_root_eval_std		X	X	2
branch_mean_spread		X	X	2
branch_value_skew	X		X	2
branching_mean_d2	X	X		2
branching_mean_d4	X	X		2
depth	X	X		2
depth_chance_inter	X	X		2
depth_deficit		X	X	2
exact_second_best_value		X	X	2
heur_incoherence	X		X	2
leaf_density		X	X	2
leaf_value_range	X		X	2
leaf_value_std_d3	X	X		2
leaf_value_std_d5	X	X		2
node_count_d4	X	X		2
total_min_nodes	X		X	2

Finalni pretprocesirani skup (`data/trees_preprocessed.csv`): 16 978 slogova, 33 atributa (`feat_A`) plus 16 ciljnih/izvedenih kolona (49 kolona ukupno).

5 Klasifikacija

5.1 Pregled eksperimenta

Glavni cilj je `which_better` (3 klase); sporedni cilj, obrađen paralelno, je `which_algo` (odjeljak 5.6), uz dodatne modele za `margin_category` i `tree_difficulty` (odjeljak 5.7) i binarne `ab_correct/mcts_correct` (odjeljak 5.5).

Eksperiment radimo na tri skupa atributa:

- **Skup A (33 atributa):** finalni pretprocesirani skup
- **Skup B (28 atributa):** samo strukturni atributi, bez ijednog merenja koje zahteva da se AB, MCTS ili orakl zaista pokrenu (`ab_nodes_visited`, `ab_ranking_correlation`, `mcts_vote_margin`, `exact_best_value`, itd.); `heur_incoherence` i `ab_reach_depth` ostaju, jer se računaju iz same strukture. Skup se dobija tako što se iz skupa A ukloni 11 atributa ponašanja algoritama (22 preostala atributa), a zatim mu se vrati 6 dodatnih strukturnih atributa koji nisu prošli izbor u odeljku 4.6 (`leaf_to_internal_ratio`, `node_count_d3`, `leaf_value_std_d2`, `chance_node_count_d2`, `total_max_nodes`, `heur_noise_param`);
- **Skup C (81 atribut):** svi prediktorski atributi originalnog skupa, bez izbora.

Skup B odgovara na centralno pitanje: *može li se, pre pokretanja ijednog algoritma, iz same strukture stabla predvideti čiji će potez biti bolji?* Razlika $B -> A$ meri vrednost merenja ponašanja algoritama; razlika $A -> C$ meri doprinos izbora atributa.

Protokol. Stratifikovana unakrsna validacija, $k=10$. Primarna metrika je macro-F1: harmonijska sredina preciznosti i odziva, izračunata posebno za svaku klasu i zatim neponderisano usrednjena, tako da model ne može da izgleda dobro samo time što pogađa najčešću klasu. Ovo je bitno jer `which_algo` ostaje neravnomeran (odeljak 2.4). Dodatno se prati i ROC AUC (jedan-naspram-ostalih, OvR): meri koliko dobro model rangira instance jedne klase iznad ostalih, nezavisno od izabranog praga odlučivanja, gde 0.5 odgovara slučajnom nagađanju, a 1.0 savršenom razdvajanju.

Korišćeni algoritmi.

- **Stablo odlučivanja (DT):** rekurzivno deli prostor atributa pragovima na pojedinačnim atributima. Lako se vizualizuje i čita direktno (odeljak 5.3), pa služi kao interpretabilna polazna tačka pre složenijih modela.
- **Slučajne šume (RF, 150 stabala):** ansambl stabala odlučivanja treniranih nad slučajnim poduzorcima podataka i atributa, čije se predikcije usrednjavaju glasanjem. Smanjuje varijansu pojedinačnog stabla i obično daje solidan rezultat bez detaljnog podešavanja hiperparametara.
- **Logistička regresija (LR):** linearni probabilistički klasifikator. Uključena je kao provera da li linearna granica između klasa uopšte može da objasni razliku.
- **XGBoost (XGB, 150 stabala):** gradijentno bustovan ansambl stabala, gde svako naredno stablo ispravlja greške prethodnih. Ona u praksi daje još bolje rezultate od prethodnih i predstavlja jači ansambl metod u poređenju.
- **Neuronska mreža (MLP, jedan skriveni sloj od 64 neurona):** uči nelinearne kombinacije atributa gradijentnim spustom. Testira da li dodatna nelinearnost donosi prednost nad modelima baziranim na stablima.
- **Metoda potpornih vektora (SVM, RBF kernel, $C=1.0$):** traži granicu odlučivanja koja maksimizuje marginu između klasa u (kernelom transformisanom) prostoru atributa.
- **Slaganje modela (Stacking: DT+RF+XGB $->$ logistička regresija)** kombinuje predikcije prethodna tri modela kao ulaz za finalnu logističku regresiju, koja uči kako da ih najbolje izmeša. Ideja je da modeli greše na različitim primerima, pa njihova kombinacija može biti robusnija od bilo kog modela pojedinačno.

5.2 Rezultati: which_better


Tabela 6: Macro-F1 po modelu i skupu atributa (10-fold, stratifikovano)

Model	A (33 atr.)	B (28 atr.)	C (81 atr.)
Stablo odlučivanja (DT)	0.622	0.470	0.564
Slučajne šume (RF)	0.679	0.554	0.649
Logistička regresija (LR)	0.679	0.557	0.652
XGBoost (XGB)	0.689	0.556	0.664
Neuronska mreža (MLP)	0.689	0.561	0.660
SVM	0.682	0.554	0.656
Slaganje modela (Stacking)	0.692	—	—

Slaganje modela na skupu A postiže najviši macro-F1 (0.692), blago iznad XGBoost-a i MLP-a (oba 0.689). Razlike među modelima na skupu A su male, što govori da je informacija u atributima već zasićena: izbor modela tu dodaje malo iznad izbora atributa. Pad sa A na B (0.679 — > 0.554 za RF) je znatan: merenja ponašanja algoritama nose realnu dodatnu vrednost, ali skup B sam po sebi, bez pokretanja algoritama, već daje macro-F1 blizu 0.55, znatno iznad slučajnog pogađanja za tri klase (≈ 0.33).


Tabela 7: Detaljne mere na skupu A (which_better, 10-fold)

Model	Tačnost	macro-F1	Preciznost	Odziv	ROC AUC (OvR)
DT	0.629	0.622	0.622	0.622	0.719
RF	0.701	0.679	0.686	0.686	0.873
LR	0.697	0.679	0.683	0.684	0.870
XGB	0.701	0.689	0.689	0.691	0.876
MLP	0.705	0.690	0.691	0.694	0.876
SVM	0.706	0.682	0.692	0.691	0.872
Stacking	0.707	0.692	0.693	0.695	0.876



Slika 11: Matrice konfuzije, svi modeli, which_better, skup A


Kada se klasa Tie u potpunosti isključi (stabla na kojima AB i MCTS biraju potez iste vrednosti), problem postaje binarna klasifikacija AB naspram MCTS na preostalih 11 294 stabala (66.5% skupa). Macro-F1 raste kod svih modela, od DT-a (0.641) do Stacking-a (0.713), koji ostaje najbolji i ovde. Isključivanje Tie-a, dakle, čini problem lakšim za sve modele podjednako, bez promene njihovog relativnog poretka.



Slika 12: Matrice konfuzije, svi modeli, `which_better` bez klase Tie, skup A

5.3 Interpretabilni model: stablo odlučivanja

Stablo odlučivanja (`max_depth=5`) trenirano na skupu B postiže tačnost 0.589 na trening skupu i deli koren po `node_budget` ≤ 130.5 . Prvi i najvažniji signal je, dakle, da li AB uopšte ima dovoljno apsolutnog budžeta na raspolaganju. Drugi po važnosti signal, dalje u stablu, je `branch_top2_gap`, strukturna margina između dva najbolja poteza iz korena.



Slika 13: Stablo odlučivanja (`max_depth=5`, skup B, `which_better`)


5.4 Važnost atributa

Tabela 8: Top 10 atributa po važnosti (skup B, `which_better`)

Slučajne šume (Gini)		XGBoost (Gain)	
<code>branch_top2_gap</code>	0.093	<code>node_budget</code>	0.186
<code>node_budget</code>	0.068	<code>branch_top2_gap</code>	0.074
<code>ab_reach_depth</code>	0.052	<code>chance_node_count_d2</code>	0.039
<code>branch_value_skew</code>	0.050	<code>ab_reach_depth</code>	0.037
<code>branch_mean_spread</code>	0.047	<code>budget_coverage</code>	0.034
<code>heur_noise_param</code>	0.045	<code>branch_mean_spread</code>	0.032
<code>budget_coverage</code>	0.045	<code>heur_noise_param</code>	0.031
<code>depth_deficit_rel</code>	0.043	<code>total_nodes</code>	0.031
<code>total_nodes</code>	0.041	<code>total_internal_nodes</code>	0.031
<code>heur_incoherence</code>	0.040	<code>total_max_nodes</code>	0.030

Oba modela slažu se da budžet (`node_budget`, `budget_coverage`) i strukturna margina korena (`branch_top2_gap`) čine jezgro najvažnijih atributa, u skladu sa stablom odlučivanja iz odeljka 5.3. Slažu se i da je `ab_reach_depth` relevantan, ali XGBoost mu dodeljuje znatno manju težinu u odnosu na sam `node_budget` (0.186 naspram 0.037), dok Slučajne šume najviše rangiraju `branch_top2_gap` (0.093).

5.5 Binarna klasifikacija: `ab_correct` i `mcts_correct`



Slika 14: ROC krive za `ab_correct` (levo) i `mcts_correct` (desno), RF, skup A naspram skupa B, 5-fold


Tabela 9: ROC AUC (RF, 5-fold CV, skup A naspram skupa B)

Cilj	Skup A	Skup B
<code>ab_correct</code>	0.825	0.696
<code>mcts_correct</code>	0.849	0.769

Razlika između skupa A i skupa B je veća za **ab_correct** nego za **mcts_correct** (tabela iznad). Atributi ponašanja algoritama, dakle, nose relativno više dodatne informacije o AB-ovoj tačnosti nego o MCTS-ovoj. Ipak, u oba slučaja skup B, koji ne sadrži nijedno merenje ponašanja algoritama, sam po sebi nosi znatan signal, daleko iznad $AUC = 0.5$ slučajnog modela. Atributi u skupu A (posebno **mcts_vote_margin** i **ab_ranking_correlation**) dodaju realnu vrednost kod oba targeta, što je očekivano jer ti atributi direktno mere sigurnost algoritma u trenutku odluke.

5.5.1 SHAP analiza greške AB algoritma

XGBoost na skupu B, cilj **ab_correct**: SHAP (SHapley Additive exPlanations) vrednosti su zasnovane na Šeplijevim vrednostima iz teorije kooperativnih igara. Pozitivna vrednost gura predikciju ka **ab_correct = 1** (AB tačan), negativna ka 0 (AB pogrešan).



Slika 15: SHAP analiza za **ab_correct** na skupu B (XGBoost)

Tabela 10: SHAP doprinosi za **ab_correct** (skup B, XGBoost)

Pozitivan doprinos (AB tačan)		Negativan doprinos (AB pogrešan)	
node_count_d3	0.091	branching_mean_d2	-0.077
ab_reach_depth	0.039	total_min_nodes	-0.038
branch_top2_gap	0.039	total_internal_nodes	-0.034
total_nodes	0.035	leaf_density	-0.018
total_max_nodes	0.032	depth_deficit	-0.015
node_count_d4	0.020	node_budget	-0.015
heur_incoherence	0.018	leaf_value_std_d3	-0.008

Najveći pojedinačni doprinos ima **node_count_d3** (pozitivan, broj čvorova na trećem nivou dubine) naspram **branching_mean_d2** (negativan, prosečan broj dece po čvoru na drugom nivou). Oba su strukturni atributi vezani za oblik stabla blizu korena, ne za budžet direktno. **total_nodes** doprinosi pozitivno (veći ukupan broj čvorova), a **node_budget** negativno (manji budžet). Zaključak je da oblik stabla u ranim nivoima i budžet zajedno nose najviše signala. **branch_top2_gap** (strukturna margina) i **heur_incoherence** (kvalitet heuristike) potvrđuju istu poruku kao stablo odlučivanja i tabela važnosti.

5.6 which_algo naspram which_better


Tabela 11: which_algo (bez klase Neither), RF/XGB, skup B, 10-fold

Model	macro-F1	std
RF	0.521	0.018
XGB	0.528	0.014

Klasa Neither (5445 stabala, 32.1%) je isključena, jer ta stabla nemaju zajednički strukturni potpis, nego samo dodaju šum bez korisnog signala za preostale tri klase. Izveštaj po klasi (RF, skup B):

Klasa	Preciznost	Odziv	F1	Broj
AB	0.61	0.52	0.56	2574
Both	0.65	0.85	0.74	6203
MCTS	0.43	0.19	0.27	2756


Poređeno sa glavnim ciljem: which_better na istom skupu B postiže RF macro-F1 = 0.554, što je iznad RF rezultata za which_algo bez klase Neither (0.521). Odbacivanje klase Neither pomaže, ali ne dovoljno da which_algo stigne which_better, što je dodatna potvrda da je pitanje čiji je potez bolji strukturno čistiji problem od pitanja ko je pogodio tačno (odjeljak 2.4).



Slika 16: Matrica konfuzije: which_algo bez Neither (RF, skup B, 10-fold)

Kada se, pored Neither, odbaci i klasa Both (ostaju samo stabla na kojima je tačno jedan od dva algoritma pogodio optimum), which_algo postaje binarna klasifikacija AB

naspram MCTS. Macro-F1 tada znatno raste: $RF = 0.712 \pm 0.019$, $XGB = 0.689 \pm 0.015$, daleko iznad rezultata sa sve tri klase. Izveštaj po klasi (RF, skup B): AB 0.72/0.67/0.69 (2574 slogova), MCTS 0.71/0.75/0.73 (2756 slogova), ukupna tačnost 0.71. Najveći deo teškoće u `which_algo` dolazi, dakle, od razdvajanja Both/Neither od preostalih klasa, a ne od razlikovanja same AB-ove i MCTS-ove greške.



Slika 17: Matrica konfuzije: `which_algo`, samo AB naspram MCTS (RF, skup B, 10-fold)

5.7 Ordinalni ciljevi: `margin_category` i `tree_difficulty`

Oba se klasifikuju Slučajnim šumama na skupu B, 10-fold CV.

Tabela 12: `margin_category` (RF, skup B, 10-fold), macro-F1 = 0.53

Klasa	Preciznost	Odziv	F1	Broj
low	0.60	0.46	0.52	5842
medium	0.53	0.70	0.61	7639
high	0.58	0.40	0.47	3497

Tabela 13: `tree_difficulty` (RF, skup B, 10-fold), macro-F1 = 0.49

Klasa	Preciznost	Odziv	F1	Broj
easy	0.58	0.70	0.63	6203
medium	0.41	0.32	0.36	5330
hard	0.50	0.49	0.49	5445

Oba modela imaju sličan, umeren macro-F1 (≈ 0.5): margina i težina stabla su delimično

predvidive iz strukture, ali daleko od trivijalno. Medium kategorija je najteže razdvojiva u oba slučaja, jer po definiciji leži na granici prema oba suseda.


6 Vizualizacije i generalizacija

6.1 Dijagram faza

Dominantna klasa `which_better` u prostoru (`ab_reach_depth` $\times$ gustina CHANCE čvorova, oba binovana u 6 intervala):

AB dominira ceo nisko-budžetni opseg bez obzira na gustinu CHANCE čvorova, jer MCTS sa malim brojem poseta po grani ne stigne da izgradi pouzdanu statistiku. Tie dominira ceo visoko budžetni opseg, jer oba algoritma tada uglavnom nađu isti ili blizak potez. MCTS izranja kao srednja traka, najizraženija baš pri višoj gustini CHANCE čvorova, gde usrednjavanje po slučajnosti otežava AB-ovu plitku heurističku procenu više nego MCTS-ovo uzorkovanje.

6.2 Preciznost rangiranja AB algoritma



Slika 18: Spirmanova korelacija AB-ovog rangiranja poteza po klasi `which_algo`

Binarna metrika `ab_correct` ne razlikuje algoritam koji bira drugi po kvalitetu potez od onog koji bira najgori. Spirmanova korelacija rangova (`ab_ranking_correlation`, $+1$ = savršeno uređivanje) pokazuje bogatiju sliku po klasi `which_algo` kod klasa gde je AB tačan (Both, AB) korelacija je visoka, preko 0.7, dok kod klasa gde formalno greši (MCTS, Neither) ostaje pozitivna, samo osetno niža, oko 0.45. AB retko pravi katastrofalnu grešku u rangiranju čak i kada formalno pogreši: identifikuje skup dobrih poteza, ali ih pogrešno rangira na margini.


6.3 Generalizacija: predikcija na nevidenom faktoru grananja

Referentna tačnost, 5-fold CV na celom skupu, skup B: `which_algo` macro-F1 = 0.402 ± 0.005 , `which_better` macro-F1 = 0.559 ± 0.008 .

Stroži test: trening bez svih stabala određenog **branching_factor**, test isključivo na njima. **bf** = 7 leži usred opsega [2, 14] (interpolacija), **bf** = 14 je ivica opsega (ekstrapolacija).

Tabela 14: Generalizacija na neviden **branching_factor** (RF, skup B)

Scenario	ab_correct		mcts_correct		which_algo		which_better	
	Tač.	F1	Tač.	F1	Tač.	F1	Tač.	F1
bf=7 (interpolacija)	0.658	0.674	0.687	0.735	0.487	0.360	0.569	0.538
bf=14 (ekstrapolacija)	0.667	0.574	0.722	0.662	0.548	0.481	0.622	0.610
bf=7 i bf=14 (oba)	0.653	0.637	0.704	0.717	0.506	0.400	0.590	0.567




Slika 19: **which_better**: predikcija iz strukturnih atributa na nevidjenim vrednostima **branching_factor**

which_better generalizuje bolje nego **which_algo** u oba scenarija (F1 0.538–0.610 naspram 0.360–0.481) i ostaje blizu svoje 5-fold reference (0.559). **which_algo** pada ispod svoje reference (0.402– > 0.360) baš na interpolisanom **bf** = 7, što je neobično: tačnost (0.487) ostaje razumna, ali F1 pada, jer model na tom specifičnom **bf** sistematski favorizuje većinsku klasu Both na štetu redih AB/MCTS predikcija. Kod ekstrapolacije na **bf** = 14 (ivica opsega), **which_algo** F1 zapravo raste na 0.481. Na najvećim stablima je klasa Neither dominantnija i lakše prepoznatljiva, što delimično kompenzuje otežanu ekstrapolaciju. Zajednička poruka: model ne uči trik vezan za konkretnu vrednost **branching_factor** (rezultati na nevidenom **bf** ne odudaraju previše), ali apsolutni nivo tačnosti zavisi od toga koja mešavina klasa dominira na tom delu opsega.

6.4 Šta čini stablo teškim

Klasa Neither (nijedan algoritam nije tačan) posebno se analizira binarnom klasifikacijom Neither naspram ostalih (XGBoost, skup B), sa SHAP analizom važnosti.



Slika 20: SHAP: prediktori teškog stabla (Neither naspram ostalih) i doprinos po dubini

Tabela 15: Top 10 prediktora teškog stabla (SHAP, skup B)

Atribut	mean(SHAP)
branch_top2_gap	0.541
ab_reach_depth	0.446
branch_mean_spread	0.385
branch_value_skew	0.312
chance_frac_top1	0.285
chance_node_count_d1	0.203
node_budget	0.175
top2_size_ratio	0.174
budget_coverage	0.173
heur_incoherence	0.169

`branch_top2_gap` je najvažniji, ali tesno praćen sa `ab_reach_depth` (0.54 naspram 0.45): strukturna margina korena i realno dostupan budžet su, dakle, podjednako jaki prediktori teškog stabla. Teška stabla su pre svega ona gde su prva dva poteza iz korena vrednosno gotovo izjednačena i/ili gde AB nema dovoljno budžeta da dosegne razumnu dubinu. Ostatak top deset atributa (`branch_mean_spread`, `branch_value_skew`, `chance_frac_top1`, `top2_size_ratio`) dodatno opisuje oblik i asimetriju grana iz korena, dok `node_budget`, `budget_coverage` i `heur_incoherence` potvrđuju da su budžet i kvalitet heuristike nezavisni dobri prediktori. Jedini atribut vezan striktno za prvi nivo dubine koji ostaje u top deset je `chance_node_count_d1`.

7 Zaključak

7.1 Sažetak nalaza

Nalaz 1. Budžet dominira nad sirovom veličinom stabla, pritom modeli se ne slažu da li ga koriste u sirovom ili normalizovanom obliku. Stablo odlučivanja deli koren direktno po `node_budget`, a XGBoost mu dodeljuje ubedljivo najveću važnost. Slučajne šume, s druge strane, i dalje najviše teže strukturnoj margini `branch_top2_gap`, sa logaritamski

izvedenim `ab_reach_depth` (koliko nivoa dubine budžet realno pokriva s obzirom na faktor grananja) tek na trećem mestu. Oba modela se slažu da je budžet centralni signal, samo se razlikuju u tome kroz koji oblik ga najbolje koriste.

Nalaz 2. Margina korena je nezavisan, podjednako jak izvor informacija. `branch_top2_gap` (razlika između prva dva poteza iz korena, računata bez pokretanja ijednog algoritma) je najvažniji pojedinačni prediktor kod Slučajnih šuma za `which_better` i ubedljivo najvažniji u SHAP analizi za to da li je stablo uopšte teško rešivo (odeljak 6.4).

Nalaz 3. `which_better` je strukturno čistiji cilj od `which_algo`. Na istom skupu strukturnih atributa (B), `which_better` dosledno nadmašuje `which_algo` (0.554 naspram 0.521 macro-F1, odeljak 5.6), bolje generalizuje na neviđene vrednosti faktora grananja (odeljak 6.3) i ima uravnoteženiju raspodelu klasa (odeljak 2.4). Razlog je strukturan, `which_algo` meša koliko je algoritam dobar sa koliko je stablo teško uopšte (klasa Both dominira kad god je bilo koji uslov ispunjen), dok `which_better` to razdvaja.

Nalaz 4. Struktura stabla je dovoljna za merljiv, ali ne potpun skup informacija. Skup B (28 atributa, isključivo strukturni) postiže macro-F1 = 0.554 za `which_better`, daleko iznad slučajnog pogađanja (≈ 0.33) ali nešto ispod skupa A koji uključuje merenja ponašanja algoritama (0.679). Ovi atributi (posebno `mcts_vote_margin`, `ab_ranking_correlation`) nose stvarnu dodatnu vrednost, ali ne menjaju koji tip strukture je bitan.

7.2 Ograničenja

Stabla su sintetička i kontrolisanog oblika, realna stabla igara (šah, Catan) imaju bogatiju strukturu i specifične evaluacione funkcije, pa generalizabilnost nalaza na stvarne igre nije eksperimentalno proverena. Iscrpni minimax kao izvor istine nije primenjiv na igre sa milijardama čvorova, pa bi na takvim igrama selekcija algoritma morala da se osloni na aproksimativan algoritam.